

- 1 read data 2 clean data 3 remove duplicated data
 4 outliers (detecting and Filtering)
 5 Feature selection 6 Data normalization

Subject: _____

Date: _____

1

4 outliers detecting

العرف

ان بلقي قيم خارج ال Range الى هي فيق بمعنى اننا عارفين
 ان متوسط الاعداد 65 سنت واتقريب عمر قد يصل الى 100 عام
 لكن ماذا عن وجبت اعمار تتجاوز 500 وال 700 هذا غير منطقي
 فهذه القيم تسمى outliers

التعرف على هذه القيم بعدة طرق

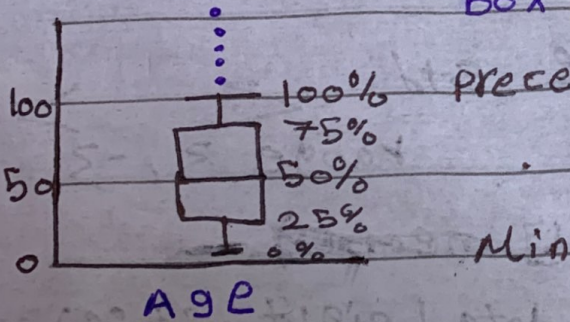
(1) عن طريق Domain Knowledge

نأعرف ان الاعداد تصل الى 100 فاهل شرط

age > 105 الى يتجاوز الشرطه يعني outliers

(2) عن طريق Visualization

Box Plot, Bar Plot



outliers
replace (, np.nan)

القيمة

2

Subject: _____

Date: _____

[1] Identify outliers by code

1- Domain

1- Identify Max-Val, min-Val

Knowledge

معرفة البيانات وقول الاشارة
المسموح بها للحدود

[1] Max-Value = data['height'].quantile(0.95)

8.37 inch منتهى فوق الحدود المسموح بها

[2] Min-Value = data['height'].quantile(0.05)

2.3 أقل من المسموح به في الدنيا

[3] Show The outliers [Identify outliers by domain]

data[data['height'] < min-value]

data[data['height'] > max-value]

name	height
essra	0.9

name	height
amr	14.9
mostafa	13.2
ibrahim	15.3

[4] Remove outliers for simple data

df[(df['height'] < max-value) & (df['height'] > min-value)]

outliers
البيانات التي هي خارج الحدود المسموح بها

البيانات

quantile